


Week4 AI Workload Network

AI Workload Network

왜 네트워크가 중요한가

- 다중 GPU 학습에서는 gradient, activation, token 등을 서로 교환해야 하므로 **네트워크 성능이 전체 학습 속도에 직접 영향을 줌**
- AI 학습은 대부분 동기식 → 한 rank의 통신이 늦으면 나머지 GPU도 대기 → GPU idle time 발생
- 일반 네트워크는 north-south(사용자 ↔ 서버) 중심이지만, AI 학습 네트워크는 **east-west(GPU 서버 간) 트래픽 중심**
- Step 경계에서 burst가 발생하므로 평균 대역폭뿐 아니라 **tail latency와 경로 예측성**이 중요

계층 구조



"NCCL이 느리다"는 증상이 있어도 원인은 GPU 내부 경로, NIC 선택, NUMA locality, fabric 혼잡, PFC/ECN 설정 등 여러 계층에 있을 수 있음

물리 경로

범위	통신 수단
GPU 서버 내부	NVLink, NVSwitch, PCIe

범위	통신 수단
GPU 서버 간	NIC/HCA → InfiniBand / RoCE / EFA

Transport 기술 비교

기술	특징
RDMA	원격 메모리에 CPU·커널 복사 없이 직접 접근. NIC/HCA가 데이터 이동 수행
InfiniBand	RDMA를 낮은 지연·높은 대역폭으로 전달하는 전용 고성능 fabric
RoCEv2	RDMA semantics를 Ethernet/IP 위에서 제공. PFC, ECN, QoS 설정이 핵심
EFA	AWS 클라우드 환경 전용 고성능 네트워크 인터페이스 및 통신 스택

Collective Communication (NCCL)

NCCL은 여러 GPU가 참여하는 collective communication을 **실제 하드웨어 토폴로지에 맞춰** 실행하는 GPU 통신 런타임.

Collective	동작	주요 사용처
AllReduce	모든 rank의 값을 합산 → 동일 결과를 전체에 배포	Data Parallel gradient sync
AllGather	각 rank의 조각을 모아 전체 데이터를 모두에게 제공	Tensor sharding, Model Parallel
ReduceScatter	합산 후 결과를 rank별로 분할 배포	ZeRO, FSDP
All-to-All	각 rank가 모든 rank에게 서로 다른 데이터를 전송	MoE expert dispatch



AI 네트워크의 본질은 GPU 연산 성능만 보는 것이 아니라,
GPU 간 데이터 이동 경로와 collective 통신 패턴을 함께 최적화하는 것.

1. RoCEv2 전송 및 혼잡 관리 기술

RoCEv2(RDMA over Converged Ethernet v2)는 **AI/ML 클러스터 내 분산 GPU 서버 간의 데이터 동기화를 위한 핵심 프로토콜**로 사용됨. 이 기술은 UDP/IP를 활용하여 GPU NIC 상에서 상태 유지 없이 효율적인 전송을 지원하며, 서버 CPU를 개입시키지 않는 제로 카피(Zero-copy) 데이터 전송을 통해 TCP 기반 방식보다 뛰어난 확장성을 제공함.

그러나 이더넷은 본질적으로 손실이 발생할 수 있는 구조이므로, 동기화가 중요한 AI 워크로드의 성능을 보장하기 위해 정교한 혼잡 관리 메커니즘이 필수적으로 요구되었음. 네트워크 내에서 발생하는 엘리펀트 플로우(Elephant Flows)는 대역폭을 독점하여 혼잡을 유발하며, 이는 GPU 간 데이터 동기화 속도를 늦추는 원인이 됨.

- **ECN (명시적 혼잡 알림):** 스위치 버퍼 임계값 초과 시 패킷 헤더에 혼잡을 마킹하고, 수신측은 이를 확인하여 송신측에 CNP(혼잡 알림 패킷)를 보냄으로써 전송 속도를 줄이게 유도함.
- **PFC (우선순위 기반 흐름 제어):** 계층 2 단계에서 특정 트래픽 클래스의 혼잡 발생 시 상위 흐름에 일시 중지 프레임(XOFF)을 보내 데이터 손실을 막는 무손실 보장 기술임.
- **DCQCN:** 조기 경보 성격의 ECN과 최종적인 무손실 보루인 PFC를 결합하여, 성능 저하와 패킷 손실을 동시에 방지하는 하이브리드 제어 방식임.
- **PFC Watchdog:** 특정 포트에서 과도한 PFC 프레임 수신으로 발생하는 'PFC 스톱'을 감지하고 차단하여 네트워크 전체의 트래픽 마비를 방지함.
- **차세대 기술 (SFC & CSIG):** 혼잡 신호를 송신측에 직접 보내는 SFC와 인밴드 텔레메트리(INT)를 활용해 실시간 경로 정보를 전달하는 CSIG 등이 연구되고 있음.

2. AI/ML 패브릭을 위한 IP 라우팅 기술

AI 데이터 센터 패브릭의 동적 IP 라우팅 프로토콜 선택은 네트워크의 수렴 속도, 확장성, 그리고 관리의 단순성에 결정적인 영향을 미침. 현재 **가장 보편적인 방식은 eBGP**를 활용한 3단계 또는 5단계 **Clos 토폴로지** 구성임.




Figure 2-1. Illustration of a common Clos topology

BGP는 원래 서비스 IP 광고를 위해 설계되었으나, 데이터 센터에서는 링크 대역폭 커뮤니티나 동일한 AS-PATH 길이 유지 등의 기법을 통해 IGP(내부 게이트웨이 프로토콜)처럼 동작하도록 미세 조정되어 사용됨. 특히 대규모 클러스터에서의 복잡한 구성을 해결하기 위해 자동화된 피어링 설정 기술이 중요하게 다뤄졌음.

- **BGP Unnumbered:** RFC 5549를 기반으로 IPv6 링크 로컬 주소를 사용하여 별도의 IPv4 주소 할당 없이도 자동으로 인접 스위치와 피어링을 맺고 IPv4 경로 정보를 교환함.
- **BGP-DPF (결정론적 경로 포워딩):** 물리적 패브릭을 논리적으로 '컬러링'하여 분할하고, 특정 GPU 플로우나 테넌트가 정해진 논리 패브릭을 통해서만 통신하도록 경로를 고정함.
- **RIFT (Routing in Fat Trees):** 팻트리 구조에 특화된 프로토콜로, 하단 노드의 경로 표 크기를 줄이고 장애 시 자동 경로 해제(Disaggregation) 기능을 통해 빠른 복구를 지원함.
- **IS-IS FlexAlgo:** 기존 라우팅 하드웨어에서 추가적인 캡슐화 없이도 지연 시간이나 대역폭 등 제약 조건에 따라 독립적인 논리적 토폴로지를 생성하고 트래픽을 격리함.
- **Segment Routing (SR/SRv6):** 소스 라우팅 방식을 통해 송신 노드에서 경로 전체를 지정하며, 컨트롤러와 연동하여 네트워크 전체의 가용 자원을 최적으로 활용하는 트래픽 엔지니어링을 수행함.



종합적으로 볼 때, 성공적인 AI 패브릭 구축을 위해서는 RoCEv2 기반의 정교한 혼잡 제어와 BGP/RIFT 등 고도화된 IP 라우팅 프로토콜의 유기적인 결합이 뒷받침되어야 함을 확인했음. 특히 400G/800G 고대역폭 환경에서는 단순한 패킷 전송을 넘어, 토폴로지 인지 기반의 부하 분산과 가시성 확보가 시스템 전체의 성능(JCT)을 결정짓는 핵심 요소로 작용했음

- **MRC(Multipath RC):**
 - **RoCEv2**의 Reliable Connection 계층을 확장한 방식. 기존 단일 경로 전송은 특정 링크나 스위치 장애, ECMP 해시 충돌, incast 혼잡이 발생하면 tail latency가 커지고 동기식 학습 job 전체가 느려지거나 실패할 수 있음. MRC는 하나의 QP 트래픽을 여러 plane과 여러 path로 뿌리고(packet spraying), ECN 기반으로 경로 상태를 보며 부하를 분산하고, 패킷이 순서대로 도착하지 않아도 바로 메모리에 배치하며, 손실 패킷만 빠르게 재전송하는 방식으로 동작함. 그래서 핵심 관점은 "네트워크 장애를 없앤다"가 아니라 "장애가 나도 job을 중단시키지 않고 남은 경로의 처리량으로 계속 진행시킨다"임. OpenAI/Microsoft의 MRC 설명에서도 MRC는 대규모 학습 클러스터에서 기존에는 training interruption을 만들던 네트워크 장애를 우회해 job이 계속 동작하도록 하는 것을 목표로 설명됨.
- **AWS EFA(Elastic Fabric Adapter):**

- 프로토콜 이름이라기보다 EC2 인스턴스에 붙이는 AWS 전용 고성능 네트워크 디바이스를 지칭. EFA는 AI/ML, HPC 애플리케이션의 inter-instance communication을 가속하기 위한 장치이며, 전통적인 TCP 기반 클라우드 HPC 보다 더 낮고 일관된 지연 시간과 높은 처리량을 제공하는 것을 목표로 함. 내부적으로 OS-bypass와 SRD(Scalable Reliable Datagram) 기반 기능을 제공하고, Libfabric을 통해 NCCL, MPI 같은 라이브러리와 연동됨. 즉 EFA는 사용자가 InfiniBand 스위치 패브릭을 직접 운영하지 않아도 AWS 네트워크 위에서 HPC/AI에 필요한 고성능 통신을 쓰게 해주는 **cloud-specific high performance stack**